

영역분할 모델 성능 향상을 위한 대조적 손실 함수의 활용

이건규¹, 황상흠²

서울과학기술대학교 데이터사이언스학과

geongyu.lee@ds.seoultech.ac.kr¹, shwang@seoultech.ac.kr²



1. 서론 - 연구 동기

• 연구 동기

- 심층 신경망을 활용한 영역 분할 모델은 다양한 영상 분석 영역에서 큰 성과를 보이고 있음
- 영역 분할을 위한 모델은 대부분 인코더-디코더 구조를 가지고 있음
- 의료 영상 분야에서 기존 연구들은 성능 향상을 위하여 모델의 복잡도를 증가 시키는 방향으로 새로운 신경망 구조를 제안 (Jha et al., 2020)


• 연구 목적

- 인코더-디코더 구조를 갖는 영역분할 모델은 인코더의 입력으로 들어간 이미지가 벡터 공간에 임베딩이 된 후 이를 바탕으로 디코더가 원본 이미지의 크기로 복원을 하는 방식으로 작동함
- 이때 다른 클래스에 해당되는 임베딩 벡터들이 벡터 공간에서 서로 멀리 위치하고, 같은 클래스에 속하는 임베딩 벡터들은 가까이 위치될 것이라는 보장이 없음
- 따라서 위와 같은 성질을 가지도록 임베딩을 한다면 모델의 성능 향상에 도움이 될 수 있을 것임

1. 서론 - 기존의 영역분할 모델들


특별한 block을 설계

- Residual block을 제안



(Zhang et al., 2017)


- DAC block을 제안



(Gu et al., 2019)


모델의 복잡도를 증가

- 2D U-Net과 3D U-Net을 같이 사용



(Li et al., 2018)


- U-Net에서 나온 결과를 다른 U-Net에 넣어서 최종 성능 향상



(Jha et al., 2020)


정보전달 방법을 개선

- U-Net의 skip-connection에 CNN을 적용



(Zhou et al., 2018)

- 모든 인코더의 정보들을 모든 디코더에 전달




(c) UNet 3+
(Huang et al., 2020)

기존 연구들은 인코더의 임베딩 성질에 대해서 다루고 있지 않음

1. 서론 - 연구 목적

- 인코더에 의한 임베딩이 가져야 할 바람직한 성질들
 - 같은 클래스에 해당되는 임베딩 벡터들 간의 거리는 가까워야 함
 - 반대로, 서로 다른 클래스에 해당되는 임베딩 벡터들 간의 거리는 멀어야 함



본 연구에서는 대조적 손실 함수를 활용하여 인코더가 위의 성질들을 가질 수 있도록 함


2. 연구 방법 – 대조적 손실 함수

- 대조적 손실 함수

- 대조적 손실 함수는 임베딩 된 벡터들의 거리를 같은 정답과는 가깝게, 다른 정답과는 멀게 해 주는 방법 (Hadsell et al., 2006)
- Positive 데이터와 negative 데이터를 혼합하여 배치 구성 (Hoffer and Ailon, 2018)
- Positive 데이터 쌍의 유사도를 활용하여 softmax 적용 (Chen et al., 2020)


$$\mathcal{L}_{contrastive} = -\log \frac{\exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{I}_{[k \neq i]} \exp(\text{sim}(z_i, z_k)/\tau)}$$

(Chen et al., 2020)



<https://towardsdatascience.com/contrastive-loss-explained-159f2d4a87ec>

2. 연구 방법 – 대조적 손실함수



- 영역 분할 문제의 경우 픽셀 단위로 정답이 존재함
- 인코더의 특징 벡터 크기로 정답데이터를 resize한 후 대조적 손실함수를 적용

3. 제안 방법 - 특징 벡터 단위 대조적 손실 함수

$$\ell_{con}(z_i, \{z^+\}_{-i}, \{z^-\}) = -\frac{1}{|\{z^+\}_{-i}|} \log \frac{\sum_{z_j \in \{z^+\}_{-i}} \exp(\text{sim}(z_i, z_j)/\tau)}{\sum_{z_k \in \{z^+\}_{-i} \cup \{z^-\}} \exp(\text{sim}(z_i, z_k)/\tau)}$$

$\{z^+\}$ 는 positive 영역의 특징 벡터들의 집합
 $\{z^-\}$ 는 negative 영역의 특징 벡터들의 집합
 z_i 는 positive 영역에서 임의로 선택된 특징 벡터
 $\text{sim}(z_i, z_j)$ 은 두 벡터의 코사인 유사도
 τ 는 temperature

- Positive 영역에 속한 특징 벡터들은 서로 거리가 가까워 지도록
negative 영역에 속한 특징 벡터들과는 서로 거리가 멀어 지도록 학습

3. 제안 방법 - 최종 손실 함수

$$\mathcal{L}_{total} = \frac{1}{|D|} \sum_{(x_i, y_i) \in D} \ell_{seg}(x_i, y_i) + \alpha \frac{1}{|\{z^+\}|} \sum_{z_i \in \{z^+\}} \ell_{con}(z_i, \{z^+\}_{-i}, \{z^-\})$$

x_i 는 영역분할 모델의 출력

y_i 는 정답 이미지



D 는 전체 데이터 셋

ℓ_{seg} 는 영역분할 모델의 손실함수 e.g) CE, DICE

- 배치사이즈가 커질수록 $\{z^+\}$ 의 크기 또한 커지게 되고 이에 따라 계산량이 증가하게 됨
 - 따라서 이중에서 랜덤하게 m 개의 샘플을 지정하여 계산

4. 실험 세팅

- CT 이미지에서 폐 영역 분할
 - Kaggle Finding and Measuring Lung in CT Data
 - 이미지 개수
 - 267장중 라벨이 잘못된 4장을 제거한 263장
 - 크기 : 512×512
 - HU = $[-1000, 400]$
- CT 이미지에서 간 영역 분할
 - The Liver Tumor Segmentation Challenge (LiTS2017)
 - 이미지 개수
 - 총 58,638장(131명) 중 간이 포함된 이미지 19,263장
 - Train / Test 를 7:3 비율로 나누어서 사용 (103명 / 28명)
 - 크기 : 330×330
 - HU = $[-200, 200]$



4. 실험 세팅

- 실험 환경


- Network

- U-Net (Ronneberger et al., 2015)
- Uet ++ (Zhou et al., 2018)


- Optimizer

- SGD(Stochastic Gradient Descent)
- Momentum = 0.9
- LR = 0.01, Decay = [75, 100], Gamma = 0.1
- Weight decay = 0.0001

- 배치 크기 : 20, 총 120 epoch



U-Net (Ronneberger et al., 2015)



U-Net++ (Zhou et al., 2018)

4. 실험 세팅 - 평가 지표

- Jaccard Similarity Coefficient (JSC)

$$Jaccard(S_x, S_y) = \frac{|S_x \cap S_y|}{|S_x \cup S_y|} = \frac{TP}{TP + FP + FN}$$

- Dice Similarity Coefficient (DSC)

$$DICE(S_x, S_y) = \frac{2 * |S_x \cap S_y|}{|S_x| + |S_y|} = \frac{2 * TP}{(TP + FP) + (TP + FN)}$$




$$\frac{blue(\text{예측}) \cap red(\text{정답})}{blue(\text{예측}) \cup red(\text{정답})}$$

- Average Contour Distance (ACD)

$$ACD(S_x, S_y) = \frac{1}{2} \left(\frac{\sum_i d(S_{xi}, S_y)}{n_{S_x}} + \frac{\sum_j d(S_{yj}, S_x)}{n_{S_y}} \right)$$

- Average Surface Distance (ASD)

$$ASD(S_x, S_y) = \frac{1}{n_{S_x} + n_{S_y}} \left(\sum_i d(S_{xi}, S_y) + \sum_j d(S_{yj}, S_x) \right)$$



$$d(S_{xi}, S_y) = \min_j \|s_{yj} - s_{xi}\|$$

S_x : segmented boundary

S_y : ground-truth boundary

5. 결과 – Hyperparameter Selection α

- Lung segmentation in CT : Kaggle data 결과

모델	α	JSC(↑)	DSC(↑)	ACD(↓)	ASD(↓)	Precision	Sensitivity	Specificity
UNET	<u>0.1</u>	0.977	0.988	0.351	0.314	0.989	0.989	0.996
	0.5	0.975	0.987	0.376	0.336	0.988	0.986	0.996
	1.0	0.974	0.986	0.459	0.399	0.988	0.985	0.996
	10.0	0.975	0.987	0.376	0.336	0.990	0.986	0.997
UNET++	<u>0.1</u>	0.980	0.990	0.317	0.290	0.991	0.990	0.997
	0.5	0.979	0.989	0.316	0.289	0.990	0.989	0.997
	1.0	0.978	0.989	0.343	0.302	0.989	0.990	0.996
	10.0	0.978	0.989	0.359	0.319	0.989	0.989	0.997



Validation 성능을 기준으로 α 를 0.1로 선정

5. 결과 - Lung segmentation in CT : Kaggle datasets

		JSC(↑)	DSC(↑)	ACD(↓)	ASD(↓)	Precision	Sensitivity	Specificity
U-NET	Base	0.970	0.980	0.463	0.311	0.990	0.989	0.997
	Ours	0.980	0.990	0.440	0.298	0.991	0.989	0.997
UNET++	Base	0.980	0.989	0.455	0.314	0.990	0.989	0.997
	Ours	0.982	0.991	0.391	0.273	0.992	0.990	0.997

- 대부분의 성능 지표에서 향상을 보임
- 특히 거리 기반 지표에서 큰 폭의 성능 향상을 보임
- 비교 모델에서 예측에 어려움이 있는 경계 부분을 더 정밀하게 예측하는 것을 확인

5. 시각화 결과 - Lung segmentation in CT : Kaggle datasets





5. 결과 - Liver segmentation in CT : LiTS2017 datasets

		JSC(↑)	DSC(↑)	ACD(↓)	ASD(↓)	Precision	Sensitivity	Specificity
U-NET	Base	0.850	0.912	0.697	0.533	0.910	0.926	0.991
	Ours	0.867	0.923	0.499	0.365	0.940	0.957	0.995
UNET++	Base	0.860	0.919	0.647	0.541	0.920	0.930	0.992
	Ours	0.877	0.924	0.460	0.321	0.930	0.943	0.995

- 모든 성능 지표에서 향상된 성능을 보이고, 폐 영역 분할 결과와 마찬가지로 거리 기반 성능 지표에서 좋은 성능을 보임



5. 시각화 결과 - Liver segmentation in CT : LiTS2017 datasets



6. 결론

- 기존 모델과 제안하는 방법을 다양한 공개 데이터 셋으로 비교실험 한 결과 대조적 손실 함수의 적용이 유의미한 성능 향상을 가져옴을 확인
- 특히 거리 기반 성능 지표의 두드러진 향상을 통해 이상적인 임베딩이 실제로 영역 분할 모델의 성능 향상에 도움이 되는 것을 확인
 - 같은 클래스에 해당하는 벡터들 간 거리는 가깝게 임베딩 되고, 다른 클래스에 해당하는 벡터들 간 거리는 멀게 임베딩 되도록 함

6. 한계점 및 추후연구



6. 한계점 및 추후연구

- 한계점

- 정답 영역이 극히 작은 경우 학습과정에서 대조적 손실 함수가 올바르게 적용 되지 않을 수 있음

- 추후 연구

- 정답 영역이 작은 경우에 대한 대조적 손실 함수의 활용 방안
- 임베딩의 바람직한 성질들을 가지도록 학습 된 인코더가 도메인 변화에 강건한지 검증

참고문헌

- Ronneberger, O., Fischer, P., & Brox, T. (2015, October). U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention* (pp. 234-241). Springer, Cham.
- Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., & Liang, J. (2018). Unet++: A nested u-net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support* (pp. 3-11). Springer, Cham.
- Isensee, F., Petersen, J., Klein, A., Zimmerer, D., Jaeger, P. F., Kohl, S., ... & Maier-Hein, K. H. (2018). nnu-net: Self-adapting framework for u-net-based medical image segmentation. *arXiv preprint arXiv:1809.10486*.
- Oktay, O., Schlemper, J., Folgoc, L. L., Lee, M., Heinrich, M., Misawa, K., ... & Glocker, B. (2018). Attention u-net: Learning where to look for the pancreas. *arXiv preprint arXiv:1804.03999*.
- Gu, Z., Cheng, J., Fu, H., Zhou, K., Hao, H., Zhao, Y., ... & Liu, J. (2019). Ce-net: Context encoder network for 2d medical image segmentation. *IEEE transactions on medical imaging*, 38(10), 2281-2292.
- He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum contrast for unsupervised visual representation learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 9729-9738).
- Misra, I., & Maaten, L. V. D. (2020). Self-supervised learning of pretext-invariant representations. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 6707-6717).
- Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A simple framework for contrastive learning of visual representations. *arXiv preprint arXiv:2002.05709*.
- Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., ... & Krishnan, D. (2020). Supervised contrastive learning. *arXiv preprint arXiv:2004.11362*.
- Huang, H., Lin, L., Tong, R., Hu, H., Zhang, Q., Iwamoto, Y., ... & Wu, J. (2020, May). UNet 3+: A Full-Scale Connected UNet for Medical Image Segmentation. In *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 1055-1059). IEEE.
- Khanna, A., Londhe, N. D., Gupta, S., & Semwal, A. (2020). A deep Residual U-Net convolutional neural network for automated lung segmentation in computed tomography images. *Biocybernetics and Biomedical Engineering*, 40(3), 1314-1327.
- Sathish, R., Sathish, R., Sethuraman, R., & Sheet, D. (2020, July). Lung Segmentation and Nodule Detection in Computed Tomography Scan using a Convolutional Neural Network Trained Adversarially using Turing Test Loss. In *2020 42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)* (pp. 1331-1334). IEEE.

감사합니다.